

Sistemas Microinformático y Redes

Proyecto Intermodular

BIG DATA CLUSTER

SPARK & HADOOP

POWERING THE FUTURE OF DATA



Francisco Gallego Perona

Jesús Enrique Félix Fernández y Gabriel Flores Vera



ÍNDICE

1-Resumen	3
2-Introducción	4
3-Análisis y contextualización de empresa/s del sector	5
3.1-Characterización de la empresa del sector	5
3.2-Productos y servicios	5
3.3-Relación con los Objetivos de Desarrollo Sostenible (ODS)	5
3.4-Identificación de los riesgos laborales	5
3.5-Conclusiones	5
4-Desarrollo del proyecto	6
4.1 Qué es HDFS	6
4.2 Qué es SPARK	6
4.3 creación del contenedor de HDFS	9
creación de APACHE Spark	13
El spark-master con los workers	14
jupyterlab	17
creación de una sesión en pyspark	18
aquí vemos que al iniciar la sesión hemos creado la primera aplicación	19
5-Resultados y Análisis	26
6-Conclusiones Recomendaciones	27
7-Bibliografía	28
8-Anexos	30

1-Resumen

Este proyecto tiene como objetivo la creación de un cluster para el procesamiento de grandes volúmenes de datos (Big Data), Utilizando como motor para analizar y procese los datos Apache Spark todo esto hecho en un contenedor (Docker)

Lo hemos hecho en Docker para crear un contenedor para facilitar la instalación de spark sin la necesidad de configurar varias máquinas físicas

Utilizamos Apache Spark para procesar todos los datos de forma rápida y eficiente. Se ejecutaron varias tareas de análisis sobre los datos

En conclusión, con este proyecto se permite comprender los conceptos básicos de Big Data, el funcionamiento de Spark y las ventajas del uso de Docker para montar el cluster.

2-Introducción

2.1 Contexto y justificación del proyecto.

Actualmente, la cantidad de datos generados ha hecho necesario el uso de tecnologías capaces de procesar grandes volúmenes de datos. El Big Data surge como respuesta a esta necesidad, permitiendo analizar datos que no podrían ser tratados con herramientas tradicionales.

El uso de Apache Spark permite comprender cómo se procesan datos de forma distribuida, mientras que Docker facilita la creación de entornos de trabajo estables y reproducibles, simplificando la instalación y configuración de los servicios necesarios.

2.2 Objetivos del proyecto.

El objetivo es hacer un cluster con Apache Spark desplegado con Docker para analizar grandes volúmenes de datos (Big Data)

Los objetivos específicos son:

- Configurar y ejecutar Apache Spark en contenedores Docker.
- Realizar tareas sencillas de procesamiento y análisis de datos.
- Comprender las ventajas del uso de Docker para el despliegue de aplicaciones.

2.3 Alcance y limitaciones del trabajo.

El alcance del proyecto se centra en la creación de un pequeño cluster de Big Data mediante contenedores Docker y con el motor de procesamiento de apache spark .

Las limitaciones del proyecto son:

- No se utiliza un cluster real con múltiples máquinas físicas.
- El volumen de datos procesado es limitado.
- no hay bases de datos grandes sin imágenes.
- no puede funcionar en equipos antiguos
- hay que pasar tiempo buscando constructores o docker-compose que estén actualizados o las imágenes aun sigan funcionando.

3-Análisis y contextualización de empresa/s del sector

3.1-Caracterización de la empresa del sector

Big Cine es una empresa perteneciente al sector tecnológico–audiovisual, especializada en la gestión, almacenamiento y análisis de grandes volúmenes de datos (big data) relacionados con el cine y el contenido audiovisual.

El sector audiovisual vinculado al big data está en crecimiento debido al aumento del consumo digital y la necesidad de analizar datos para mejorar la toma de decisiones. Ofrece oportunidades de innovación y expansión, aunque presenta riesgos como la alta competencia y la dependencia tecnológica.

3.2-Productos y servicios

Big Cine ofrece servicios de almacenamiento, análisis y explotación de datos cinematográficos, elaboración de informes, sistemas de recomendación y consultoría para empresas del sector audiovisual.

Su público objetivo son productoras, plataformas de streaming, instituciones culturales y educativas.

Se diferencia de la competencia por su especialización exclusiva en datos cinematográficos y su análisis avanzado.

3.3-Relación con los Objetivos de Desarrollo Sostenible (ODS)

Big Cine se relaciona con:

ODS 9 (Innovación e infraestructura) mediante el uso de tecnología avanzada.

ODS 8 (Trabajo decente) al generar empleo cualificado.

ODS 12 (Producción responsable) al optimizar recursos mediante análisis de datos.

ODS 4 (Educación de calidad) apoyando la investigación y el aprendizaje.

3.4-Identificación de los riesgos laborales

Los principales riesgos laborales son ergonómicos, psicosociales, fatiga visual y sedentarismo, derivados del trabajo prolongado con equipos informáticos. Es necesario aplicar medidas preventivas como ergonomía adecuada y pausas activas.

3.5-Conclusiones

Big Cine representa un modelo de empresa innovadora que combina cine y big data en un sector en expansión. Como oportunidades de mejora destacan el refuerzo de la seguridad de datos, la mejora del bienestar laboral y el desarrollo de servicios educativos y sostenibles.

4-Desarrollo del proyecto

4.1 Qué es HDFS

HDFS es el sistema de gestión de almacenamiento principal de Hadoop algo que se puede sacar del significado de las siglas Hadoop Distributed File System (Sistema de distribución de ficheros de hadoop). HDFS es bastante eficiente en lo que trata a Big Data ya que divide los datos en bloques y los replica en todos los datanode gracias a eso es también es a prueba de fallos y tiene una recuperación fácil de hardware al tener copias de los datos en todos los datanodes

Estos son los dos tipos de nodos en HDFS

Namenode: Se encarga de saber dónde están los archivos, los permisos que tienen y la ubicación del bloque. También controla el acceso de los clientes a los archivos y realiza operaciones como abrir, cerrar y renombrar directorios y archivos

Datanode: Son los que se encargan de la creación, eliminación y replicación de bloques, además de las solicitudes de escritura y lectura.

4.2 Qué es SPARK

SPARK es el motor de procesamiento de datos el puede gestionar grandes cantidades de datos por eso se utiliza bastante en Big Data y se adapta bien a PySpark. En general SPARK gracias a su velocidad computacional, escalabilidad y la programabilidad necesaria para Big Data, específicamente para la transmisión de datos, datos gráficos, análisis, machine learning, procesamiento de datos a gran escala y aplicaciones de inteligencia artificial (IA).


Estos son los tipos de nodos que tiene SPARK

Spark-master: Es el nodo central en spark el cual se encarga de administrar los recursos y coordinar a los workers. El es el que registra a los workers, asigna los recursos y monitorea aplicaciones


Spark-worker: Se encarga de que recibe la tarea del master y la ejecuta, procesa los datos y reporta su estado y uso de recursos al Master.

HDFS


HDFS Architecture



SPARK



JupyterLab + Spark + HDFS



4.3 creación del contenedor de HDFS

Aquí tenemos el .yaml para montar el contenedor de HDFS aquí ponemos el namenode y el datanode y lo ponemos en una red docker llamada bigdata_movies

```
GNU nano 7.2
services:
  namenode:
    image: bde2020/hadoop-namenode:2.0.0-hadoop3.2.1-java8
    container_name: namenode
    ports:
      - "9870:9870"
      - "9000:9000"
    environment:
      - CLUSTER_NAME=hdfs-cluster
      - CORE_CONF_fs_defaultFS=hdfs://namenode:9000
      - CORE_CONF_hadoop_staticuser_user=root
      - HDFS_CONF_dfs_replication=1
    volumes:
      - namenode:/hadoop/dfs/name
    networks:
      - bigdata_movies

  datanode:
    image: bde2020/hadoop-datanode:2.0.0-hadoop3.2.1-java8
    container_name: datanode
    environment:
      - CLUSTER_NAME=hdfs-cluster
      - CORE_CONF_fs_defaultFS=hdfs://namenode:9000
      - CORE_CONF_hadoop_http_staticuser_user=root
      - HDFS_CONF_dfs_replication=1
    depends_on:
      - namenode
    volumes:
      - datanode:/hadoop/dfs/data
    networks:
      - bigdata_movies

volumes:
  namenode:
  datanode:

networks:
  bigdata_movies:
    external: true
```

Docker compose up para que construya el contenedor .

```
alusrmr@adrianl:~/Documentos/HDFS$ docker compose up -d
WARN[0000] /home/alusrmr/Documentos/HDFS/docker-compose.yml: the attribute `version` is obsolete, it will
be ignored, please remove it to avoid potential confusion
[+] Running 18/18
  ✓ namenode Pulled                                         56.6s
  ✓ facffb3a6de3 Pull complete                             54.8s
  ✓ c71a6df73788 Pull complete                             54.9s
  ✓ 73b8c0ccb707 Pull complete                             54.9s
  ✓ datanode Pulled                                         56.6s
  ✓ 3192219afd04 Pull complete                             10.3s
  ✓ 7127a1d8cccd Pull complete                             28.6s
  ✓ 883a89599900 Pull complete                             28.7s
  ✓ 77920a3e82af Pull complete                             28.7s
  ✓ 92329e81aec4 Pull complete                             54.6s
  ✓ f373218fec59 Pull complete                             54.6s
  ✓ aa53513fe997 Pull complete                             54.7s
  ✓ 8b1800105b98 Pull complete                             54.7s
  ✓ c3a84a3e49c8 Pull complete                             54.7s
  ✓ a65640a64a76 Pull complete                             54.8s
  ✓ 3ca2ec07878c Pull complete                             54.8s
  ✓ 26c2dd45430e Pull complete                             54.9s
  ✓ 13c9c87a46cb Pull complete                             54.9s
[+] Running 5/5
  ✓ Network hdfs_default      Created                                0.1s
  ✓ Volume "hdfs_namenode"    Created                                0.0s
  ✓ Volume "hdfs_datanode"    Created                                0.0s
  ✓ Container namenode        Started                                0.4s
  ✓ Container datanode        Started                                0.3s
alusrmr@adrianl:~/Documentos/HDFS$ docker exec -it namenode bash
root@fc23dcc9e3b4:/# hdfs dfs -ls /
root@fc23dcc9e3b4:/# hdfs dfs -mkdir /cinebeni
root@fc23dcc9e3b4:/# hdfs dfs -ls /
Found 1 items
drwxr-xr-x   - root supergroup          0 2026-01-22 18:18 /cinebeni
root@fc23dcc9e3b4:/# exit
exit
alusrmr@adrianl:~/Documentos/HDFS$ docker network create bigcine-net
9c0bc28e952277f707963aaee877a150319404da29e6f71be2d971d5cdb1c7c3
alusrmr@adrianl:~/Documentos/HDFS$
```

Vemos que tenemos el contenedor creado con los puerto accedemos a la interfaz grafica

☐	▼	☐	hdfs	-	-	-	▶	⋮	🗑
☐		☐	datanode	39734263c59c	bde2020/h		▶	⋮	🗑
☐		☐	namenode	4e51c245d47d	bde2020/h	9000:9000	▶	⋮	🗑
							Show all ports (2)		

Esta es la interfaz que vemos si vamos al puerto que nos aparece en docker y vemos que nos sale un nodo vivo eso significa que el datanode que hemos hecho se ha conectado correctamente. esto no salio a la segunda porque a la primera no se podia conectar

Hadoop	Overview	Datanodes	Datanode Volume Failures	Snapshot	Startup Progress	Utilities ▾
--------	----------	-----------	--------------------------	----------	------------------	-------------

Overview 'namenode:9000' (active)

Started:	Sat Jan 31 18:23:08 +0100 2026
Version:	3.2.1, rb3cbbb467e22ea829b3808f4b7b01d07e0bf3842
Compiled:	Tue Sep 10 17:56:00 +0200 2019 by rohitsharmaks from branch-3.2.1
Cluster ID:	CID-8fb1bde5-a097-45b6-ba2d-36c60cfb83ea
Block Pool ID:	BP-521904238-172.19.0.2-1769880187100

Summary

Security is off.

Safemode is off.

1 files and directories, 0 blocks (0 replicated blocks, 0 erasure coded block groups) = 1 total filesystem object(s).

Heap Memory used 137.57 MB of 471.5 MB Heap Memory. Max Heap Memory is 3.45 GB.

Non Heap Memory used 56.97 MB of 58.25 MB Committed Non Heap Memory. Max Non Heap Memory is <unbounded>.

Configured Capacity:	1006.85 GB
Configured Remote Capacity:	0 B
DFS Used:	24 KB (0%)
Non DFS Used:	28.48 GB
DFS Remaining:	927.16 GB (92.09%)
Block Pool Used:	24 KB (0%)
DataNodes usages% (Min/Median/Max/stdDev):	0.00% / 0.00% / 0.00% / 0.00%
Live Nodes	1 (Decommissioned: 0, In Maintenance: 0)
Dead Nodes	0 (Decommissioned: 0, In Maintenance: 0)
Decommissioning Nodes	0
Entering Maintenance Nodes	0
Total Datanode Volume Failures	0 (0 B)
Number of Under-Replicated Blocks	0
Number of Blocks Pending Deletion (including replicas)	0
Block Deletion Start Time	Sat Jan 31 18:23:08 +0100 2026
Last Checkpoint Time	Sat Jan 31 18:23:07 +0100 2026

subir archivos a HDFS mediante comandos

```
alusmr@adrianl:~/Documentos/HDFS$ ls
actors.csv  docker-compose.yml  languages.csv  releases.csv  themes.csv
crew.csv    genres.csv          posters.csv   studios.csv
alusmr@adrianl:~/Documentos/HDFS$ docker cp themes.csv namenode:/tmp/themes.csv
Successfully copied 5.56MB to namenode:/tmp/themes.csv
alusmr@adrianl:~/Documentos/HDFS$ docker cp studios.csv namenode:/tmp/studios.csv
Successfully copied 18.3MB to namenode:/tmp/studios.csv
alusmr@adrianl:~/Documentos/HDFS$ docker cp releases.csv namenode:/tmp/releases.csv
Successfully copied 51.2MB to namenode:/tmp/releases.csv
alusmr@adrianl:~/Documentos/HDFS$ docker cp languages.csv namenode:/tmp/languages.csv
Successfully copied 28.6MB to namenode:/tmp/languages.csv
alusmr@adrianl:~/Documentos/HDFS$ docker cp posters.csv namenode:/tmp/posters.csv
Successfully copied 94.9MB to namenode:/tmp/posters.csv
alusmr@adrianl:~/Documentos/HDFS$ docker cp genres.csv namenode:/tmp/genres.csv
Successfully copied 17.9MB to namenode:/tmp/genres.csv
alusmr@adrianl:~/Documentos/HDFS$ docker cp crew.csv namenode:/tmp/crew.csv
Successfully copied 162MB to namenode:/tmp/crew.csv
alusmr@adrianl:~/Documentos/HDFS$ docker cp movies.csv namenode:/tmp/movies.csv
Successfully copied 254MB to namenode:/tmp/movies.csv
alusmr@adrianl:~/Documentos/HDFS$ docker exec -it namenode hdfs dfs -put /tmp/movies.csv /data/
2026-02-02 20:13:23,311 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted
= false, remoteHostTrusted = false
2026-02-02 20:13:23,636 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted
= false, remoteHostTrusted = false
alusmr@adrianl:~/Documentos/HDFS$ docker exec -it namenode hdfs dfs -put /tmp/genres.csv /data/
2026-02-02 20:13:34,064 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted
= false, remoteHostTrusted = false
alusmr@adrianl:~/Documentos/HDFS$ docker exec -it namenode hdfs dfs -put /tmp/languages.csv /data/
2026-02-02 20:13:44,830 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted
= false, remoteHostTrusted = false
^[[Aalusmr@adrianl:~/Documentos/HDFS$ docker exec -it namenode hdfs dfs -put /tmp/themes.csv /data/
2026-02-02 20:13:55,402 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted
= false, remoteHostTrusted = false
alusmr@adrianl:~/Documentos/HDFS$ docker exec -it namenode hdfs dfs -put /tmp/posters.csv /data/
2026-02-02 20:14:07,965 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted
= false, remoteHostTrusted = false
alusmr@adrianl:~/Documentos/HDFS$ docker exec -it namenode hdfs dfs -put /tmp/studio.csv /data/
put: `/tmp/studio.csv': No such file or directory
alusmr@adrianl:~/Documentos/HDFS$ docker exec -it namenode hdfs dfs -put /tmp/studios.csv /data/
2026-02-02 20:14:20,410 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted
= false, remoteHostTrusted = false
alusmr@adrianl:~/Documentos/HDFS$ docker exec -it namenode hdfs dfs -put /tmp/releases.csv /data/
2026-02-02 20:14:38,718 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted
= false, remoteHostTrusted = false
alusmr@adrianl:~/Documentos/HDFS$ docker exec -it namenode hdfs dfs -put /tmp/crew.csv /data/
2026-02-02 20:14:51,121 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted
= false, remoteHostTrusted = false
2026-02-02 20:14:51,480 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted
= false, remoteHostTrusted = false
alusmr@adrianl:~/Documentos/HDFS$
```

Creación de APACHE Spark

Si buscamos un docker compose para construir el contenedor hay que verificar que las imágenes del compose sigan existiendo. Con este tuvimos más problemas que con HDFS ya que siempre daba problemas al construirlo porque no encontraba las imágenes o no eran compatibles y luego que el master no conocía a los workers

```
GNU nano 8.4                                docker-compose.yml
volumes:
  shared-workspace:
    name: "cluster_tfg"
services:
  spark-master:
    image: andreper/spark-master
    container_name: spark-master
    hostname: spark-master
    environment:
      - SPARK_MODE=master
    ports:
      - "7077:7077"
      - "8080:8080"
    volumes:
      - shared-workspace:/opt/workspace
    networks:
      - bigdata_movies

  spark-worker-1:
    image: andreper/spark-worker
    container_name: spark-worker-1
    depends_on:
      - spark-master
    environment:
      - SPARK_MODE=worker
      - SPARK_MASTER_URL=spark://spark-master:7077
      - SPARK_WORKER_CORES=2
      - SPARK_WORKER_MEMORY=1024m
    ports:
      - "8081:8081"
    volumes:
      - shared-workspace:/opt/workspace
    networks:
      - bigdata_movies

  spark-worker-2:
    image: andreper/spark-worker
    container_name: spark-worker-2
    depends_on:
      - spark-master
    environment:
      - SPARK_MODE=worker
      - SPARK_MASTER_URL=spark://spark-master:7077
      - SPARK_WORKER_CORES=2
      - SPARK_WORKER_MEMORY=1024m
    ports:
      - "8082:8081"
    volumes:
      - shared-workspace:/opt/workspace
    networks:
      - bigdata_movies

  jupyterlab:
    image: andreper/jupyterlab
    container_name: jupyterlab
    depends_on:
      - spark-master
    environment:
      - SPARK_MASTER=spark://spark-master:7077
    ports:
      - "8888:8888"
    volumes:
      - shared-workspace:/opt/workspace
    networks:
      - bigdata_movies
```

hacemos el docker compose up y monto los contenedores de jupyterlab, spark-master y dos workers

```

[+] up 21/226944e      Pull complete      0.9s
✓ Image andreper/jupyterlab Pulled      180.6s
✓ Image andreper/spark-worker Pulled      127.1s
✓ Image andreper/spark-master Pulled      127.1s
✓ Volume cluster_tfg Created      0.0s
✓ Container spark-master Created      1.3s
✓ Container spark-worker-1 Created      0.2s
✓ Container jupyterlab Created      0.2s
✓ Container spark-worker-2 Created      0.2s

```

aqui vemos el docker de spark creado con el master, los 2 worker y el jupyterlab

☐	▼	☐	spark	-	-	-			
☐		☐	worker-1	47697721c50d	andreper/s	8081:8081			
☐		☐	worker-2	419ea69d3cf0		andreper/s 8082:8081			
☐		☐	master	eb9e71b9cb9b	andreper/s	7077:7077 Show all ports (2)			
☐		☐	jupyterlab	06ee36274c5b	andreper/ju	4040:4040 Show all ports (2)			

El spark-master con los workers

aqui vemos el master, en el master vemos los dos workers que hemos creado y que están vivos
esi significa que funcionan y se detectan entre ellos

Spark Master at spark://spark-master:7077

URL: spark://spark-master:7077
Alive Workers: 2
Cores in use: 2 Total, 0 Used
Memory in use: 1024.0 MiB Total, 0.0 B Used
Resources in use:
Applications: 0 Running, 0 Completed
Drivers: 0 Running, 0 Completed
Status: ALIVE

Workers (2)

Worker Id	Address	State	Cores	Memory	Resources
worker-20260128193705-172.20.0.4-33009	172.20.0.4:33009	ALIVE	1 (0 Used)	512.0 MiB (0.0 B Used)	
worker-20260128193705-172.20.0.5-41615	172.20.0.5:41615	ALIVE	1 (0 Used)	512.0 MiB (0.0 B Used)	

Running Applications (0)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration
----------------	------	-------	---------------------	------------------------	----------------	------	-------	----------

Completed Applications (0)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration
----------------	------	-------	---------------------	------------------------	----------------	------	-------	----------

Aqui se ve en los log del master como aparece como que el a sido elegido como maestro y que se han registrado los dos workers

```
26/02/13 12:16:08 INFO Master: I have been elected leader! New state: ALIVE
26/02/13 12:16:08 INFO Master: Registering worker 172.22.0.3:46189 with 2 cores, 1024.0 MiB RAM
26/02/13 12:16:08 INFO Master: Registering worker 172.22.0.4:38691 with 2 cores, 1024.0 MiB RAM
```

spark-worker1

The screenshot shows a web browser window with the URL `http://localhost:8082`. The page title is "Spark Worker at 172.20.0.4:33009". The Apache Spark logo (3.5.7) is visible. The page displays the following information:

- ID: worker-20260128193705-172.20.0.4-33009
- Master URL:
- Cores: 1 (0 Used)
- Memory: 512.0 MiB (0.0 B Used)
- Resources:

A link "Back to Master" is present. Below, a section "Running Executors (0)" is shown with a table that has columns: ExecutorID, State, Cores, Memory, Resources, Job Details, and Logs. The table is currently empty.

En los logs de worker sale que se intenta conectar al máster por la dirección que le hemos dado al hacerlo con el .yml en la siguiente línea ya dice que se ha podido conectar y en la última que sea registrado

```
26/02/13 12:16:08 INFO Worker: Connecting to master spark-master:7077...
26/02/13 12:16:08 INFO TransportClientFactory: Successfully created connection to spark-master/172.22.0.2:7077 after 46 ms (0 ms spent in bootstraps)
26/02/13 12:16:08 INFO Worker: Successfully registered with master spark://spark-master:7077
```

spark-worker2

The screenshot shows a web browser window with the URL `http://localhost:8081`. The page title is "Spark Worker at 172.20.0.5:41615". The Apache Spark logo (3.5.7) is visible. The page displays the following information:


- ID: worker-20260128193705-172.20.0.5-41615
- Master URL: spark://spark-master:7077
- Cores: 1 (0 Used)
- Memory: 512.0 MiB (0.0 B Used)
- Resources:

A link "Back to Master" is present. Below, a section "Running Executors (0)" is shown with a table that has columns: ExecutorID, State, Cores, Memory, Resources, Job Details, and Logs. The table is currently empty.

```
26/02/13 12:16:08 INFO Worker: Connecting to master spark-master:7077...
26/02/13 12:16:08 INFO TransportClientFactory: Successfully created connection to spark-
master/172.22.0.2:7077 after 51 ms (0 ms spent in bootstraps)
26/02/13 12:16:08 INFO Worker: Successfully registered with master spark://spark-master:7077
```

jupyterlab

en jupyterlab es donde mandamos trabajos al master y el se lo manda a los workers



The screenshot shows the JupyterLab interface. On the left is a file browser with a table of files:

	Modified
	2mo ago
ipyynb	next yr.

The main area is a code editor titled "Untitled.ipynb" with a toolbar and a dropdown menu set to "Python 3 (ipykernel)". The code in the editor is:

```
[5]: from pyspark.sql import SparkSession

spark = (
    SparkSession.builder
        .appName("jupyter-spark")
        .master("spark://spark-master:7077")
        .getOrCreate()
)

spark
```

Below the code editor, the console output is displayed in a light red background. It shows the default log level set to "WARN" and a warning message from NativeCodeLoader. Below the console output, the SparkSession configuration is shown:

```
[5]: SparkSession - in-memory

SparkContext

Spark UI


Version      v3.5.7
Master       spark://spark-master:7077
AppName      jupyter-spark
```

Below the configuration, another warning message is shown in the console output. At the bottom, the output of the code execution is shown:

```
[3]: spark
```

creación de una sesión en pyspark

1º importando desde pyspark.sql la spark session generamos la sesión marcando el nombre de la app que vamos hacer y dónde está el master y ponemos spark al final para que muestre la sesión|.



The screenshot shows a Jupyter Notebook interface with a file browser on the left and a code editor on the right. The file browser shows a folder named 'Untitled.ipynb' and a file named 'next yr.'. The code editor shows the following code:

```
[5]: from pyspark.sql import SparkSession

spark = (
    SparkSession.builder
    .appName("jupyter-spark")
    .master("spark://spark-master:7077")
    .getOrCreate()
)

spark
```

The output of the code is displayed below the code cell. It shows the default log level set to "WARN" and a warning message about the native-hadoop library. The output also shows the SparkSession object and its properties:

```
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use
setLogLevel(newLevel).
26/01/31 11:42:54 WARN NativeCodeLoader: Unable to load native-hadoop
library for your platform... using builtin-java classes where applicab
le

[5]: SparkSession - in-memory

SparkContext

Spark UI

Version      v3.5.7
Master       spark://spark-master:7077
AppName      jupyter-spark

26/01/31 11:43:09 WARN GarbageCollectionMetrics: To enable non-built-i
n garbage collector(s) List(G1 Concurrent GC), users should configure
it(them) to spark.eventLog.gcMetrics.youngGenerationGarbageCollectors
or spark.eventLog.gcMetrics.oldGenerationGarbageCollectors

[3]: spark
```

aquí vemos que al iniciar la sesión hemos creado la primera aplicación

 3.5.7

Spark Master at spark://spark-master:7077

URL: spark://spark-master:7077
Alive Workers: 2
Cores in use: 4 Total, 4 Used
Memory in use: 2.0 GiB Total, 2.0 GiB Used
Resources in use:
Applications: 1 [Running](#), 0 [Completed](#)
Drivers: 0 Running, 0 Completed
Status: ALIVE

Workers (2)

Worker Id	Address	State	Cores	Memory	Resources
worker-20260131112914-172.18.0.3-35513	172.18.0.3:35513	ALIVE	2 (2 Used)	1024.0 MiB (1024.0 MiB Used)	
worker-20260131112914-172.18.0.4-41469	172.18.0.4:41469	ALIVE	2 (2 Used)	1024.0 MiB (1024.0 MiB Used)	

Running Applications (1)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration
app-20260131114254-0000 (kill)	jupyter-spark	4	1024.0 MiB		2026/01/31 11:42:54	root	RUNNING	4.2 min

Completed Applications (0)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration
----------------	------	-------	---------------------	------------------------	----------------	------	-------	----------

Aqui vemos a la aplicación y datos de ella.



3.5.7

Application: jupyter-spark

ID: app-20260131114254-0000

Name: jupyter-spark

User: root

Cores: Unlimited (4 granted)

Executor Limit: Unlimited (2 granted)

Executor Memory - Default Resource Profile: 1024.0 MiB

Executor Resources - Default Resource Profile:

Submit Date: 2026/01/31 11:42:54

State: RUNNING

Application Detail UI

▼ Executor Summary (2)

ExecutorID	Worker	Cores	Memory	Resource Profile Id	Resources	State	Logs
1	worker-20260131112914-172.18.0.3-35513	2	1024	0		RUNNING	stdout stderr
0	worker-20260131112914-172.18.0.4-41469	2	1024	0		RUNNING	stdout stderr

Aquí vemos que está completa eso es cuando se mata una sesión



3.5.7

Spark Master at spark://spark-master:7077

URL: spark://spark-master:7077

Alive Workers: 2

Cores in use: 4 Total, 0 Used

Memory in use: 2.0 GiB Total, 0.0 B Used

Resources in use:

Applications: 0 Running, 1 Completed

Drivers: 0 Running, 0 Completed

Status: ALIVE

▼ Workers (2)

Worker Id	Address	State	Cores	Memory	Resources
worker-20260131112914-172.18.0.3-35513	172.18.0.3:35513	ALIVE	2 (0 Used)	1024.0 MiB (0.0 B Used)	
worker-20260131112914-172.18.0.4-41469	172.18.0.4:41469	ALIVE	2 (0 Used)	1024.0 MiB (0.0 B Used)	

▼ Running Applications (0)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration
----------------	------	-------	---------------------	------------------------	----------------	------	-------	----------

▼ Completed Applications (1)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration
app-20260131114254-0000	jupyter-spark	4	1024.0 MiB		2026/01/31 11:42:54	root	KILLED	21 min



Spark Worker at 172.18.0.4:41469

ID: worker-20260131112914-172.18.0.4-41469

Master URL: spark://spark-master:7077

Cores: 2 (2 Used)

Memory: 1024.0 MiB (1024.0 MiB Used)

Resources:

[Back to Master](#)

▼ Running Executors (1)

ExecutorID	State	Cores	Memory	Resources	Job Details	Logs
0	RUNNING	2	1024.0 MiB		ID: app-20260131120832-0001 Name: movies User: root	stdout stderr

▼ Finished Executors (1)

ExecutorID	State	Cores	Memory	Resources	Job Details	Logs
0	KILLED	2	1024.0 MiB		ID: app-20260131114254-0000 Name: jupyter-spark User: root	stdout stderr

Lo segundo que hacemos es decirle a spark que lea el documento dentro de hdfs el cual tenemos que poner la ruta y que meta la cabecera que es la primera fila y que las ponga del tipo que son.

The screenshot shows a Jupyter Notebook with a file explorer on the left and a code editor on the right. The code editor contains the following code:

```
[1]: SparkSession - in-memory

SparkContext

Spark UI

Version: v3.5.7
Master: spark://spark-master:7077
AppName: movies

26/02/13 12:48:28 WARN GarbageCollectionMetrics: To enable non-built-in garbage collector(s) List(G1 Concurrent GC), users should configure it(them) to spark.eventLog.gcMetrics.youngGenerationGarbageCollectors or spark.eventLog.g.cMetrics.oldGenerationGarbageCollectors

[4]: movies = spark.read.csv(
    "hdfs://namenode:9000/data/movies.csv",
    header=True,
    inferSchema=True
)
movies.show()
```

The output of the code is a table of movie data:

id	name	date	tagline	description	minute	rating
1000001	Barbie	2023	She's everything...	Barbie and Ken ar...	114	3.86
1000002	Parasite	2019	Act like you own ...	All unemployed, K...	133	4.56
1000003	Everything Everyw...	2022	The universe is s...	An aging Chinese ...	140	4.3
1000004	Fight Club	1999	Mischief. Mayhem...	"A ticking-time-b...	139	4.3
1000005	La La Land	2016	Here's to the foo...	Mia, an aspiring ...	129	4.09
1000006	Oppenheimer	2023	The world forever...	The story of J. R...	181	4.23
1000007	Interstellar	2014	Mankind was born ...	The adventures of...	169	4.35
1000008	Joker	2019	Put on a happy face.	During the 1980s,...	122	3.85
1000009	Dune	2021	Beyond fear, dest...	Paul Atreides, a ...	155	3.9
1000010	Pulp Fiction	1994	Just because you ...	A burger-loving h...	154	4.26
1000011	Spider-Man: Into ...	2018	More than one wea...	"Struggling to fi...	117	4.3
1000012	Whiplash	2014	The road to great...	Under the directi...	107	4.43
1000013	The Batman	2022	Unmask the truth.	In his second yea...	177	3.98
1000014	Get Out	2017	Just because you'...	Chris and his gir...	104	4.16
1000015	Knives Out	2019	Hell, any of them...	When renowned cri...	131	3.99
1000016	Midsommar	2019	Let the festivit...	Several friends t...	147	3.78
1000017	The Dark Knight	2008	Why So Serious?	Batman raises the...	152	4.47
1000018	Inception	2010	Your mind is the ...	"Cobb, a skilled ...	148	4.3
1000019	Saltburn	2023	We're all about t...	Struggling to fin...	131	3.43
1000020	Poor Things	2023	She's like nothin...	Brought back to l...	142	4.05

only showing top 20 rows

Estos son los logs que han salido al ejecutarlo que es el trabajo haciéndose y que ha guardado el archivo. Los stage son los pasos que tiene que hacer o que van haciendo para hacer un trabajo

The screenshot shows a terminal window with the following output:

```
[Stage 1:> (0 + 4) / 4]

[Stage 1:=====> (2 + 2) / 4]

[I 2026-02-13 12:50:38.168 ServerApp] Saving file at /Untitled.ipynb
```

CONSULTAS

Pedimos que nos enseñe el nombre y la fecha de las películas si no le marcamos un número exacto en .show() siempre enseñara las primeras 20.


```
: movies.select(['name', 'date']).show()
```

```
+-----+
|          name|date|
+-----+
|          Barbie|2023|
|          Parasite|2019|
|Everything Everyw...|2022|
|          Fight Club|1999|
|          La La Land|2016|
|          Oppenheimer|2023|
|          Interstellar|2014|
|          Joker|2019|
|          Dune|2021|
|          Pulp Fiction|1994|
|Spider-Man: Into ...|2018|
|          Whiplash|2014|
|          The Batman|2022|
|          Get Out|2017|
|          Knives Out|2019|
|          Midsommar|2019|
|          The Dark Knight|2008|
|          Inception|2010|
|          Saltburn|2023|
|          Poor Things|2023|
+-----+
only showing top 20 rows
```

Movies.create Or Replace Temp View: crea una vista temporal del dataframe en esta ocasión le da un nombre en este caso el nombre movies para hacer las consultas con sql.

Aquí nos seleccione el nombre de películas que sean del 1999.

```
movies.createOrReplaceTempView("movies")
```

```
spark.sql("select name from movies").filter(movies.date == "1999").show()
```

```
+-----+
|          name|
+-----+
|          Fight Club|
|10 Things I Hate ...|
|          The Matrix|
|Star Wars: Episod...|
|          American Beauty|
|          Eyes Wide Shut|
|          Girl, Interrupted|
|          The Virgin Suicides|
|          Toy Story 2|
|          The Sixth Sense|
|          The Green Mile|
|          Notting Hill|
|          Magnolia|
|The Blair Witch P...|
|But I'm a Cheerle...|
|Being John Malkovich|
|          The Iron Giant|
|The Talented Mr. ...|
|          The Mummy|
|          Tarzan|
+-----+
only showing top 20 rows
```

Creando consultas en la primera pedimos que nos de las películas del 2006 y que empiezan por ever.

```
# Filtramos las películas donde el año de la columna 'date' sea 2006
movies_2006 = movies.filter(year("date") == 2006)

# Mostramos el resultado
movies_2006.show()
```

id	name	date	tagline	description	minute	rating
1000095	Little Miss Sunshine	2006	A family on the v...	A family loaded w...	102	4.17
1000125	The Devil Wears P...	2006	Meet Andy Sachs. ...	Andy moves to New...	109	3.78
1000173	The Prestige	2006	Are You Watching ...	A mysterious stor...	130	4.23
1000199	The Departed	2006	Lies. Betrayal. S...	To take down Sout...	151	4.31
1000316	Cars	2006	Ahhh... it's got ...	Lightning McQueen...	117	3.7
1000325	Pan's Labyrinth	2006	What happens when...	Living with her t...	118	4.16
1000419	Children of Men	2006	The future's a th...	In 2027, in a cha...	109	4.3
1000447	Marie Antoinette	2006	Rumor. Scandal. F...	The retelling of ...	123	3.73
1000472	Pirates of the Ca...	2006	Jack is back!	Captain Jack Spar...	151	3.62
1000490	Casino Royale	2006	Everyone has a pa...	Le Chiffre, a ban...	144	4.01
1000529	Paprika	2006	This is your brai...	When a machine th...	90	4.08
1000568	Borat: Cultural L...	2006	Come to Kazakhsta...	Kazakh journalist...	84	3.73
1000579	The Pursuit of Ha...	2006	NULL	A struggling sale...	117	3.88
1000585	Night at the Museum	2006	Where History Com...	Chaos reigns at t...	108	3.26
1000641	The Holiday	2006	It's Christmas Ev...	Two women, one fr...	136	3.48
1000765	She's the Man	2006	If you wanna chas...	Viola Johnson is ...	105	3.34
1000787	High School Musical	2006	This School Rocks...	Troy, the popular...	98	3.16
1000861		300	2006	Spartans, prepare... where the King o... and helped usher...		
1000885	Monster House	2006	The house is . . .	Monsters under th...	91	3.36
1000886	Click	2006	What If You Had A...	A harried workaho...	107	2.83

only showing top 20 rows

```
movies.filter(col("name").startswith("ever")).show()
```

id	name	date	tagline	description	minute	rating
1271003	everyday star	2019	NULL	Everyday states o...	9	NULL
1273467	every dog has its...	2019	NULL	Cult-produced med...	6	NULL
1355669	every light retur...	2020	NULL	Filmed on both si...	7	NULL
1362157	everydayPeople	2011	NULL	Two small western...	66	NULL
1386652	everyone gets to ...	NULL	NULL	everyone gets to ...	19	NULL
1403236	everything takes ...	2020	NULL	"We see, and so w... even dreams"" ex... moving between t...		
1406455	everything must go	NULL	NULL	Fresh off their n...	12	NULL
1413560	everything I didn...	2023	NULL	Atlas sees the sa...	5	NULL
1435980	everything will b...	NULL	NULL	Contemplating abo...	1	NULL
1442431	everything in our...	NULL	NULL	Part film, part e...	5	NULL
1531003	ever present goin...	2007	NULL	Filmmaker Philip ...	7	NULL
1577457	everything is bea...	2022	NULL	Queer, post-roman...	5	NULL
1608885	everything is fine	2021	It just doesn't a...	Following a famil...	8	NULL
1611918	everything is ok ...	2021	NULL	A destructive col...	6	NULL
1669946	everyone deceives...	1992	NULL	"Buthaina is a bu... a thief broke i...	95	
1671870	everything finds ...	2021	NULL	You think a bit o...	NULL	NULL
1688261	everything circle...	2023	NULL	This poem is buil...	4	NULL
1725743	every dove is a p...	2024	A film about the ...	every dove is a p...	14	NULL

0- En el primer bloque hacemos que lea todos archivos.csv que están en HDFS y que meta la cabecera que es la primera fila de la columna y que sepa los tipos de columnas que son .

1- Hacemos un diccionario para que haga como índice para acceder más fácilmente a cada Dataframe

2- Definimos qué columna específica quieres extraer de cada tabla secundaria.

3- en este paso agrupamos todas las filas que pertenezcan a una misma película para evitar los duplicados a la hora de imprimir o ver las listas

4- En el último bloque seleccionamos las columnas finales y las renombramos para que sean mas legibles, todo eso lo metemos en un tempview llamado tabla_cine para poder hacer consultas a tabla_cine directamente.

```
from pyspark.sql import functions as F

# --- PASO 0: CARGA REAL DE DATOS ---
# (Aquí es donde definimos las variables que te daban error)
df_mov = spark.read.csv("hdfs://namenode:9000/data/archive/movies.csv", header=True, inferSchema=True)
df_lan = spark.read.csv("hdfs://namenode:9000/data/archive/languages.csv", header=True, inferSchema=True)
df_gen = spark.read.csv("hdfs://namenode:9000/data/archive/genres.csv", header=True, inferSchema=True)
df_act = spark.read.csv("hdfs://namenode:9000/data/archive/actors.csv", header=True, inferSchema=True)
df_cou = spark.read.csv("hdfs://namenode:9000/data/archive/countries.csv", header=True, inferSchema=True)
df_cre = spark.read.csv("hdfs://namenode:9000/data/archive/crew.csv", header=True, inferSchema=True)
df_rel = spark.read.csv("hdfs://namenode:9000/data/archive/releases.csv", header=True, inferSchema=True)
df_std = spark.read.csv("hdfs://namenode:9000/data/archive/studios.csv", header=True, inferSchema=True)
df_thm = spark.read.csv("hdfs://namenode:9000/data/archive/themes.csv", header=True, inferSchema=True)

# --- PASO 1: Ahora sí, definimos el diccionario ---
processed_dfs = {
    "mov": df_mov,
    "lan": df_lan,
    "gen": df_gen,
    "act": df_act,
    "cou": df_cou,
    "cre": df_cre,
    "rel": df_rel,
    "std": df_std,
    "thm": df_thm
}

# --- PASO 2: Configuración de columnas ---
config_tablas = {
    "lan": "language",
    "gen": "genre",
    "act": "name",
    "cou": "country",
    "cre": "role",
    "rel": "date",
    "std": "studio",
    "thm": "theme"
}

# --- PASO 3: Agrupación y Join (El resto de tu código) ---
tablas_agrupadas = {}
for alias, col_nombre in config_tablas.items():
    tablas_agrupadas[alias] = processed_dfs[alias] \
        .groupBy("id") \
        .agg(F.collect_set(col_nombre).alias(f"list_{alias}"))

final_df = processed_dfs["mov"]
for alias in config_tablas.keys():
    final_df = final_df.join(tablas_agrupadas[alias], "id", "left")

# --- PASO 4: Selección y Vista Temporal ---
resultado = final_df.select(
    F.col("id"),
    F.col("name").alias("movie_title"),
    F.col("date").alias("release_date"),
    F.col("minute").cast("int"),
    F.col("rating").cast("float"),
    F.col("list_gen").alias("genres"),
    F.col("list_lan").alias("languages"),
    F.col("list_act").alias("actors")
).orderBy("id")

resultado.createOrReplaceTempView("tabla_cine")
resultado.show(5)
```

Esta es una consulta para buscar el nombre de una película que sea Barbie.

```
spark.sql("SELECT * FROM tabla_cine WHERE movie_title LIKE '%Barbie%').show()
```

```
[Stage 44:>                                     (0 + 4) / 5]
+-----+-----+-----+-----+-----+-----+-----+
| id|      movie_title|release_date|minute|rating|      genres|languages|      actors|
+-----+-----+-----+-----+-----+-----+-----+
|1000001|      Barbie|      2023|    114|    3.86|[Adventure, Comedy]| [English]| [Ellis Harman, Be...|
|1002463|Barbie as The Pri...|      2004|     85|    3.92|[Comedy, Animatio...]| [English]| [Lee Tockar, Ian ...|
|1003087|Barbie in The 12 ...|      2006|     82|    3.92|[Animation, Family]| [English]| [Catherine O'Hara...|
|1003707|Barbie: Princess ...|      2011|     79|    3.86|[Fantasy, Animati...]| [English]| [Brittney Wilson,...|
|1003833|Barbie and the Di...|      2008|     78|    3.81|[Animation, Family]| [English]| [Maryke Hendrikse...|
|1003838|Barbie of Swan Lake|      2003|     83|    3.5|[Animation, Family]| [English]| [Kelsey Grammer, ...|
|1004016|Barbie in the Nut...|      2001|    NULL|    77.0|[Animation, Family]| [English]| [Ian James Corlet...|
|1004183|Barbie as Rapunzel|      2002|     84|    3.45|[Animation, Family]| [English]| [Ian James Corlet...|
|1004564|Barbie in A Merma...|      2010|     75|    3.61|[Fantasy, Animati...]| [English]| [Maryke Hendrikse...|
|1004712|Barbie and the Ma...|      2005|     85|    3.57|[Romance, Animati...]| [English]| [Stevie Vallance,...|
|1004743|Barbie: Fairytopia|      2005|     70|    3.37|[Animation, Family]| [English]| [Lee Tockar, Nanc...|
|1004844|Barbie as the Isl...|      2007|     85|    3.44|[Animation, Family]| [English]| [Ian James Corlet...|
|1004985|Barbie Fairytopia...|      2006|     75|    3.55|[Fantasy, Adventu...]| [English]| [Brittney Wilson,...|
|1004992|Barbie and the Th...|      2009|     81|    3.63|[Animation, Family]| [English]| [Willow Johnson, ...|
|1005177|Barbie: A Fashion...|      2010|     79|    3.69|[Animation, Family]| [English]| [Alexa Devine, Ma...|
|1005707|Barbie: The Princ...|      2012|     86|    3.23|[Animation, Family]| [English]| [Allison Warnyca,...|
|1005820|Barbie: A Fairy S...|      2011|     72|    3.52|[Fantasy, Animati...]| [English]| [Brittney Wilson,...|
|1006081|Barbie Mariposa|      2008|     75|    3.35|[Fantasy, Animati...]| [English]| [Cathy Weseluck, ...|
|1006280|Barbie in A Chris...|      2008|     76|    3.35|[Animation, Family]| [English]| [Tabitha St. Germ...|
|1006951|Barbie Fairytopia...|      2007|     75|    3.27|[Fantasy, Romance...]| [English]| [Lee Tockar, Nanc...|
+-----+-----+-----+-----+-----+-----+-----+
only showing top 20 rows
```

Aqui pedimos películas que sean de acción.

```
# La forma correcta de buscar en una lista
spark.sql("SELECT * FROM tabla_cine WHERE array_contains(genres, 'Action')").show()
```

```
[Stage 53:>                                     (0 + 4) / 5]
+-----+-----+-----+-----+-----+-----+-----+
| id|      movie_title|release_date|minute|rating|      genres|      languages|      actors|
+-----+-----+-----+-----+-----+-----+-----+
|1000003|Everything Everyw...|      2022|    140|    4.3|[Action, Science ...]| [Chinese, Cantone...]| [Stephanie Hsu, R...|
|1000011|Spider-Man: Into ...|      2018|    NULL|   117.0|[Action, Adventur...]| [Spanish, Japanes...]| [Al Rodrigo, Luna...|
|1000017|The Dark Knight|      2008|    152|    4.47|[Thriller, Action...]| [Chinese, English]| [Michael Stoyanov...|
|1000018|Inception|      2010|    NULL|   148.0|[Action, Adventur...]| [Swahili, French,...]| [Shannon Welles, ...|
|1000021|Spider-Man: Acros...|      2023|    140|    4.45|[Action, Adventur...]| [Italian, Spanish...]| [Nic Novicki, Ric...|
|1000027|Spider-Man: No Wa...|      2021|    148|    3.84|[Action, Adventur...]| [Tagalog, English]| [Ben VanderMey, W...|
|1000040|Avengers: Infini...|      2018|    149|    3.96|[Action, Science ...]| [Xhosa, English]| [Mark Ruffalo, Et...|
|1000043|Avengers: Endgame|      2019|    181|    3.87|[Action, Science ...]| [Xhosa, Japanese,...]| [Ken Jeong, Mark ...|
|1000044|Baby Driver|      2017|    113|    3.72|[Action, Crime]| [English]| [Colin Lacativa, ...|
|1000045|Kill Bill: Vol. 1|      2003|    111|    4.19|[Action, Crime]| [French, Japanese...]| [Akaji Maro, Sô Y...|
|1000056|Scott Pilgrim vs....|      2010|    113|    3.87|[Action, Comedy, ...]| [English]| [Jung-Yul Kim, Ch...|
|1000057|The Matrix|      1999|    136|    4.16|[Action, Science ...]| [English]| [Luke Quinton, Da...|
|1000062|Guardians of the ...|      2014|    121|    3.78|[Action, Adventur...]| [English]| [Isabella Poynton...|
|1000063|Black Panther|      2018|    135|    3.65|[Action, Adventur...]| [Swahili, Korean,...]| [Christine Hollin...|
|1000067|The Lord of the R...|      2001|    179|    4.37|[Fantasy, Action,...]| [English]| [Mana Hira Davis,...|
|1000072|Mad Max: Fury Road|      2015|    121|    4.19|[Action, Adventur...]| [English]| [Vincent Roxburgh...|
|1000082|Star Wars|      1977|    121|    4.17|[Action, Adventur...]| [English]| [David Ankrum, Ma...|
|1000083|Avatar: The Way o...|      2022|    192|    3.61|[Action, Adventur...]| [English]| [Jemaine Clement,...|
|1000084|Guardians of the ...|      2023|    150|    3.96|[Action, Adventur...]| [English]| [Maria Bakalova, ...|
|1000085|Spider-Man: Homec...|      2017|    133|    3.47|[Action, Adventur...]| [English]| [Gary Richardson,...|
+-----+-----+-----+-----+-----+-----+-----+
only showing top 20 rows
```

aqui estamos pidiendo película que cumplan con dos parámetros que sea de acción y tengan una calificación mayor que menor o igual que 10.

```
8]: spark.sql(""" SELECT * FROM tabla_cine WHERE array_contains(genres, 'Action') AND rating <= 10 """).show()
```

```
[Stage 103:=====] (2 + 2) / 5
```

id	movie_title	release_date	minute	rating	genres	languages	actors
1000003	Everything Everyw...	2022	140	4.3	[Action, Science ...]	[Chinese, Cantone...]	[Stephanie Hsu, R...]
1000017	The Dark Knight	2008	152	4.47	[Thriller, Action...]	[Chinese, English]	[Michael Stoyanov...]
1000021	Spider-Man: Acros...	2023	140	4.45	[Action, Adventur...]	[Italian, Spanish...]	[Nic Novicki, Ric...]
1000027	Spider-Man: No Wa...	2021	148	3.84	[Action, Adventur...]	[Tagalog, English]	[Ben VanderMey, W...]
1000040	Avengers: Infini...	2018	149	3.96	[Action, Science ...]	[Xhosa, English]	[Mark Ruffalo, Et...]
1000043	Avengers: Endgame	2019	181	3.87	[Action, Science ...]	[Xhosa, Japanese,...]	[Ken Jeong, Mark ...]
1000044	Baby Driver	2017	113	3.72	[Action, Crime]	[English]	[Colin Lacativa, ...]
1000045	Kill Bill: Vol. 1	2003	111	4.19	[Action, Crime]	[French, Japanese...]	[Akaji Maro, Sô Y...]
1000056	Scott Pilgrim vs. ...	2010	113	3.87	[Action, Comedy, ...]	[English]	[Jung-Yul Kim, Ch...]
1000057	The Matrix	1999	136	4.16	[Action, Science ...]	[English]	[Luke Quinton, Da...]
1000062	Guardians of the ...	2014	121	3.78	[Action, Adventur...]	[English]	[Isabella Poynton...]
1000063	Black Panther	2018	135	3.65	[Action, Adventur...]	[Swahili, Korean,...]	[Christine Hollin...]
1000067	The Lord of the R...	2001	179	4.37	[Fantasy, Action,...]	[English]	[Mana Hira Davis,...]
1000072	Mad Max: Fury Road	2015	121	4.19	[Action, Adventur...]	[English]	[Vincent Roxburgh...]
1000082	Star Wars	1977	121	4.17	[Action, Adventur...]	[English]	[David Ankrum, Ma...]
1000083	Avatar: The Way o...	2022	192	3.61	[Action, Adventur...]	[English]	[Jemaine Clement,...]
1000084	Guardians of the ...	2023	150	3.96	[Action, Adventur...]	[English]	[Maria Bakalova, ...]
1000085	Spider-Man: Homec...	2017	133	3.47	[Action, Adventur...]	[English]	[Gary Richardson,...]
1000088	Top Gun: Maverick	2022	131	3.99	[Action, Drama]	[English]	[Manny Jacinto, C...]
1000096	Deadpool	2016	108	3.67	[Action, Adventur...]	[English]	[Ayzee, Aatash Am...]

only showing top 20 rows

Esto sería una consulta de una película exacta ya que le pasamos los años y el nombre de la película.

```
9]: spark.sql("SELECT * FROM tabla_cine WHERE release_date LIKE '%1994%' AND movie_title = 'Pulp Fiction'").show()
```

```
[Stage 112:=====] (4 + 1) / 5
```


id	movie_title	release_date	minute	rating	genres	languages	actors
1000010	Pulp Fiction	1994	154	4.26	[Thriller, Crime]	[Spanish, French,...]	[Susan Griffiths,...]

Aqui es que el idioma sea francés y la fecha de estreno sea 2020

```
: CT movie_title, release_date, languages FROM tabla_cine WHERE array_contains(languages, 'French') AND release_date LIKE '%2020%').show()
```

movie_title	release_date	languages
The Queen's Gambit	2020	[Spanish, French,...]
Hamilton	2020	[French, English]
The Half of It	2020	[Chinese, Spanish...]
Da 5 Bloods	2020	[Vietnamese, Fren...]
The Old Guard	2020	[Italian, Arabic,...]
My Octopus Teacher	2020	[French, English]
On the Rocks	2020	[Spanish, French,...]
Summer of 85	2020	[French, English]
365 Days	2020	[Italian, French,...]
Dolittle	2020	[French, English]
Rebecca	2020	[French, English]
Dating Amber	2020	[French, English]
Alone	2020	[French, English]
Ava	2020	[German, French, ...]
Class Action Park	2020	[French, English]
We Can Be Heroes	2020	[Moldavian, Frenc...]
Escape from Pretoria	2020	[French, English]
Mandibles	2020	[French]
My Spy	2020	[French, English]
Cuties	2020	[French, Wolof]

only showing top 20 rows



5-Resultados y Análisis

El resultado al que hemos llegado es tener un cluster de spark para el proceso de datos. Por jupyterlab hacemos la sesión en spark, las consultas que hacemos para buscar lo que queremos dentro de una base de datos la cual son varios archivos que hemos podido unir todo dentro de un tempview y para que no hubiera duplicación de filas unirlos por id. y en hdfs hemos almacenado los datos que hemos utilizado en nuestro cluster.

6-Conclusiones Recomendaciones

En conclusión hemos hecho un proyecto a una escala pequeña al hacerlo en docker ya que esto se haría en una empresa con varios nodos, con una cantidad de workers suficientes para no obstruir la red y con base de datos más extensa y consultas más complejas que las que hemos hecho en este proyecto.

Mejoras: en vez de hacerlo en un docker hacer que cada nodo sea un ordenador/servidor con sus propios recursos así haciendo que todo no tire de los recursos de una misma máquina así potenciando el nivel del procesamiento de datos y de almacenamiento y más seguridad a la hora de pérdida de datos porque falle un servidor luego los datos se replican en varios bloques de datanode.

7-Bibliografía

<https://github.com/pacotoh/bd-ia-courses/blob/main/notebooks/bda/IntroPySpark.ipynb>

<https://hub.docker.com/u/andreper>

<https://hub.docker.com/r/gchq/hdfs>

<https://www.ibm.com/es-es/think/topics/hdfs>

<https://www.ibm.com/es-es/think/topics/apache-spark>

8-Anexos